



GRACE HOPPER · MATERIAL DE REVISÃO

Lista de exercícios: Modelos Preditivos

Do raciocínio conceitual à avaliação de modelos, com questões de asserção–razão, objetivas, somatório e desafios abertos.

Maria Eduarda

30 questões

Gabarito comentado

Nome: _____

Data: _____

Como aproveitar esta lista

Resolva primeiro sem consultar o material. Depois, explique em voz alta por que sua resposta faz sentido. Em ciência de dados, justificar uma decisão vale tanto quanto marcar uma alternativa.

Convenção das questões de asserção–razão

- A. As duas afirmações são verdadeiras, e a razão justifica a asserção.
- B. As duas são verdadeiras, mas a razão não justifica a asserção.
- C. A asserção é verdadeira, e a razão é falsa.
- D. A asserção é falsa, e a razão é verdadeira.
- E. As duas afirmações são falsas.

PARTE 1

10 questões de asserção–razão

Classifique cada par usando as alternativas A–E apresentadas acima.

1 Analise as afirmações

Asserção: A padronização das features é especialmente importante no KNN.

Razão: O KNN compara exemplos por distância, e uma variável com escala muito maior pode dominar esse cálculo.

Resposta: _____ **Justificativa curta:** _____

2 Analise as afirmações

Asserção: A regressão logística pode produzir uma probabilidade para a classe positiva.

Razão: A função sigmoide transforma qualquer valor real em um número entre 0 e 1.

Resposta: _____ **Justificativa curta:** _____

3 Analise as afirmações

Asserção: Uma acurácia de 95% sempre prova que um classificador é adequado.

Razão: Em bases desbalanceadas, um modelo pode ignorar a classe rara e ainda obter acurácia elevada.

Resposta: _____ **Justificativa curta:** _____

4 Analise as afirmações

Asserção: Random Forest tende a ser mais estável do que uma única árvore de decisão.

Razão: Ela combina o voto de árvores treinadas com variações de amostras e features.

Resposta: _____ **Justificativa curta:** _____

5 Analise as afirmações

Asserção: É recomendável padronizar variáveis antes de aplicar K-Means.

Razão: O algoritmo forma grupos minimizando distâncias até os centroides.

Resposta: _____ **Justificativa curta:** _____

6 Analise as afirmações

Asserção: Alta precisão significa que há poucos falsos positivos entre as previsões positivas.

Razão: A precisão é calculada por $TP \div (TP + FN)$.

Resposta: _____ **Justificativa curta:** _____

7 Analise as afirmações

Asserção: Recall é importante quando deixar um caso positivo passar tem custo alto.

Razão: O recall diminui quando existem muitos falsos negativos.

Resposta: _____ **Justificativa curta:** _____

8 Analise as afirmações

Asserção: Durante o treino, o KNN estima vários coeficientes para formar uma equação.

Razão: O KNN armazena os exemplos e adia a decisão até receber um novo ponto.

Resposta: _____ **Justificativa curta:** _____

9 Analise as afirmações

Asserção: Naive Bayes costuma funcionar bem na classificação de textos.

Razão: A hipótese de independência condicional simplifica a combinação das evidências de muitas palavras.

Resposta: _____ **Justificativa curta:** _____

10 Analise as afirmações

Asserção: Depois de usar cross-validation, não é mais necessário manter um conjunto de teste final.

Razão: A cross-validation estima a estabilidade do modelo repetindo treino e validação em diferentes folds.

Resposta: _____ **Justificativa curta:** _____

PARTE 2

10 questões objetivas e de somatório

Marque a melhor alternativa. Nos itens de somatório, some os valores das afirmações corretas.

11 Tipo de problema

Qual alternativa contém, nessa ordem, um problema de **classificação** e um de **regressão**?

- A) Prever preço de uma casa; prever temperatura.
- B) Detectar fraude; estimar o valor de uma compra.
- C) Agrupar clientes; detectar spam.
- D) Prever duração; segmentar imagens.

12 Métricas pela matriz

Um modelo obteve $TP=36$, $TN=48$, $FP=12$ e $FN=4$. Qual alternativa está correta?

- A) Acurácia 84%, precisão 75% e recall 90%.
- B) Acurácia 90%, precisão 84% e recall 75%.
- C) Acurácia 75%, precisão 90% e recall 84%.
- D) Acurácia 84%, precisão 90% e recall 75%.

13 Escolha de K no KNN

Qual estratégia é mais adequada?

- A) Usar sempre $K=1$.
- B) Escolher K pelo conjunto de teste.
- C) Testar valores de K na validação, preferindo valor ímpar em classificação binária.
- D) Usar o número de features como K.

14 Elbow Method

No K-Means, o “cotovelo” indica:

- A) O ponto em que aumentar K deixa de reduzir muito a inércia.
- B) A maior acurácia possível.
- C) O melhor threshold da regressão logística.
- D) A quantidade de valores nulos.

15 Data leakage

Qual situação apresenta vazamento de dados?

- A) Separar treino e teste antes de ajustar o scaler.
- B) Criar uma feature usando informação registrada depois do evento que queremos prever.
- C) Remover uma coluna identificadora.
- D) Calcular métricas no conjunto de validação.

16 Somatório — avaliação

Some os valores das afirmações corretas.

- 01 — Precision considera os falsos positivos.
- 02 — Recall considera os falsos negativos.
- 04 — F1 combina precision e recall.
- 08 — R^2 só pode assumir valores entre 0 e 1.
- 16 — MAE está na mesma unidade da variável alvo.

Soma: _____

17 Somatório — clustering

Some os valores das afirmações corretas.

- 01 — K-Means precisa receber K.
- 02 — Silhouette alta sugere grupos compactos e separados.
- 04 — DBSCAN pode marcar pontos como ruído.
- 08 — Clustering exige rótulos conhecidos.
- 16 — Distância e escala das features influenciam os grupos.

Soma: _____

18 Naive Bayes

Qual frase descreve melhor o modelo?

- A) Constrói várias árvores e combina votos.
- B) Atualiza probabilidades com evidências, assumindo independência condicional entre features.
- C) Forma grupos usando centroides.
- D) Usa apenas o exemplo mais distante.

19 Métrica alinhada ao risco

Em uma triagem de doença grave, perder uma pessoa doente é muito custoso. Qual métrica deve receber atenção especial?

- A) Recall da classe doente.
- B) Apenas acurácia.
- C) R^2 .
- D) Inércia.

20 Feature engineering

Para prever cancelamento de assinatura, qual feature é útil e segura?

- A) "Cancelou no mês seguinte".
- B) Identificador aleatório do cliente.
- C) Número de dias desde o último acesso, calculado até a data da previsão.
- D) Resultado final copiado para uma nova coluna.

PARTE 3

10 questões abertas e práticas

Mostre seu raciocínio. Diagramas, contas e pseudocódigo são bem-vindos.

21 Construa uma matriz de confusão

Em 100 transações, 20 eram fraudes. O modelo detectou 16 dessas fraudes e gerou 10 alarmes falsos. Monte a matriz de confusão com TP, TN, FP e FN. Depois calcule acurácia, precision, recall e F1.

22 Explique e aplique o KNN

Explique o KNN para alguém que nunca estudou machine learning. Depois, considere o novo ponto $Q=(5,4)$ e $K=3$:

Ponto	Coordenada	Classe
A	(4,4)	Rosa
B	(6,5)	Rosa
C	(5,2)	Azul
D	(9,8)	Azul
E	(2,1)	Azul

Calcule ou compare as distâncias, escolha as três vizinhas e indique a classe prevista. Por que a escala das variáveis importa?

23 Uma rodada de K-Means

Temos os valores 1, 2, 3, 8, 9 e 10. Use $K=2$ e centroides iniciais $C_1=2$ e $C_2=9$. Faça uma rodada: atribua cada valor ao centro mais próximo e calcule os novos centroides. Explique quando o algoritmo para.

24 Regressão versus classificação

Explique a diferença considerando: tipo de saída, dois exemplos reais, algoritmos possíveis e métricas adequadas. Classifique os problemas: preço de apartamento, risco “baixo/médio/alto”, quantidade vendida e detecção de spam.

25 Feature engineering — Titanic

Você recebeu as colunas Name, Sex, Age, SibSp, Parch, Ticket, Fare, Cabin e Embarked. Proponha pelo menos cinco features novas ou transformações. Para cada uma, explique a hipótese e como evitar leakage.

Pista: família a bordo, título no nome, tamanho do grupo, cabine conhecida e tarifa por pessoa podem revelar padrões.

26 Código escrito à mão — pipeline

Complete o código para carregar, investigar, preparar, treinar e avaliar um classificador no Titanic. Não é necessário executar.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix

df = pd.read_csv("_____")

# 1. Mostre formato, tipos, nulos e distribuição do alvo
_____

X = _____
y = _____
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=____, random_state=42, stratify=____
)

# 2. Defina colunas numéricas e categóricas
numeric_features = _____
categorical_features = _____

# 3. Crie preprocessamento e pipeline sem leakage
_____
_____

# 4. Treine, faça previsões e avalie
_____
_____
```

27 Código escrito à mão — métricas

Sem usar scikit-learn, escreva funções ou pseudocódigo que recebam TP, TN, FP e FN e retornem acurácia, precision, recall e F1. Trate divisão por zero.

28 Escolha e defenda um modelo

Uma empresa tem poucos milhares de exemplos, precisa explicar decisões a clientes e possui classes desbalanceadas. Compare Regressão Logística, KNN, Naive Bayes, Decision Tree e Random Forest. Escolha um ponto de partida e descreva como validaria sua decisão.

29 Naive Bayes em palavras

Explique prior, likelihood e posterior usando uma analogia de investigação. Por que a hipótese “naive” pode ser irreal? Mesmo assim, por que o modelo pode funcionar bem para textos?

30 Desafio de projeto

Escolha um problema real que você gostaria de resolver. Defina alvo, unidade de observação, possíveis features, tipo de aprendizagem, modelo inicial, divisão dos dados, métrica principal, baseline e um risco ético ou operacional.

GABARITO

Respostas e critérios de correção

Consulte somente depois de tentar. Em questões abertas, outras respostas bem justificadas também podem ser válidas.

Asserção–razão

1. **A** — Distância depende da escala.

2. **A** — A sigmoide viabiliza interpretação probabilística.

3. **D** — A asserção é absoluta e falsa; a razão explica o risco.

4. **A** — Diversidade e votação reduzem variância.

5. **A** — K-Means otimiza distâncias.

6. **C** — $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$, não usa FN.

7. **A** — FN reduz recall.

8. **D** — KNN é um método baseado em instâncias.

9. **A** — A simplificação torna o cálculo eficiente.

10. **D** — Ainda precisamos de teste final independente.

Objetivas

11. B

12. A

13. C

14. A

15. B

16. 23 (01+02+04+16)

17. 23 (01+02+04+16)

18. B

19. A

20. C

Guia das abertas

21. Matriz e métricas

TP=16, FN=4, FP=10 e TN=70. Acurácia=86%; precision=16/26≈61,5%; recall=16/20=80%; F1≈69,6%.

22. KNN

As três menores distâncias são A=1, B=√2 e C=2; a votação prevê **Rosa** por 2 a 1. Espera-se explicar votação/média, escolha de K e padronização.

23. K-Means

Grupo 1={1,2,3}, novo $C_1=2$; grupo 2={8,9,10}, novo $C_2=9$. Para quando atribuições ou centroides deixam de mudar, ou ao atingir o limite definido.

24. Regressão e classificação

Regressão prevê valor contínuo e pode usar MAE/RMSE/ R^2 ; classificação prevê categoria/probabilidade e pode usar precision/recall/F1/ROC-AUC. Preço e quantidade são regressão; risco categórico e spam são classificação.

25. Feature engineering

Exemplos: $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$, `IsAlone`, título extraído de `Name`, `FarePerPerson`, `deck` extraído de `Cabin`, `HasCabin`, tamanho do grupo por `Ticket` e faixas de idade. Transformações aprendidas devem ser ajustadas apenas no treino.

26. Pipeline

O caminho correto é `/kaggle/input/competitions/titanic/train.csv`. Espera-se usar `info`, `isna().sum()` e `value_counts`; separar `Survived`; imputar, codificar e escalar dentro de `ColumnTransformer/Pipeline`; ajustar no treino e avaliar no teste.

27. Métricas à mão

```
accuracy = (tp + tn) / (tp + tn + fp + fn)
precision = tp / (tp + fp)
recall    = tp / (tp + fn)
f1        = 2 * precision * recall / (precision + recall)
# se o denominador for zero, retornar 0 ou registrar como indefinido
```

28–30. Critérios

- **28:** comparar interpretabilidade, escala, custo, desbalanceamento e validação; justificar métrica e baseline.
- **29:** explicar atualização de crença e independência condicional; relacionar texto a contagens esparsas.
- **30:** apresentar problema coerente, alvo observável, features disponíveis antes da previsão, validação correta, métrica alinhada e análise de risco.